

第六题：MNIST 分类中 SGD 与自然梯度训练的对比

2026 年 7 月 3 日

1 题目与实现说明

第六题要求构建神经网络对 MNIST 数据集中的 0-9 手写数字进行分类，并分别使用随机梯度下降（SGD）和自然梯度（Natural Gradient, NG）训练，最后比较训练结果。

本解答的程序为 `mnist_sgd_ng.py`。程序优先读取标准 MNIST IDX 文件，包括训练图像、训练标签、测试图像和测试标签四个文件；文件名可带 `.gz` 后缀。若这些文件放在 `data/mnist` 中，可直接运行：

```
python mnist_sgd_ng.py --mnist-dir data/mnist --require-mnist.
```

当前工作目录中没有 MNIST IDX 文件，且运行环境无网络下载数据，因此本次代码验证使用程序内置的可复现 `MNIST-like` 离线数字数据。该数据同样为 28×28 灰度图、10 类分类，用于验证训练、评估和对比流程；真实 MNIST 只需替换数据文件即可复现实验流程。

2 神经网络模型

采用一个单隐层多层感知机（MLP）：

$$h = \text{ReLU}(xW_1 + b_1), \quad p_\theta(y | x) = \text{softmax}(hW_2 + b_2),$$

其中输入 $x \in \mathbb{R}^{784}$ ，隐层维度为 64，输出层为 10 类。损失函数为带 L_2 正则项的交叉熵：

$$\mathcal{L}(\theta) = -\frac{1}{n} \sum_{i=1}^n \log p_\theta(y_i | x_i) + \frac{\lambda}{2} (\|W_1\|_2^2 + \|W_2\|_2^2).$$

3 SGD 与自然梯度方法

SGD 直接沿小批量梯度的反方向更新参数：

$$\theta_{t+1} = \theta_t - \eta \hat{g}_t,$$

其中 $\hat{g}_t = \nabla_\theta \mathcal{L}_B(\theta_t)$ 为当前 minibatch 的梯度。

自然梯度的思想是不用欧氏距离衡量参数变化，而用模型分布诱导出的 Fisher 信息矩阵 $F(\theta)$ 衡量参数空间的局部几何：

$$\theta_{t+1} = \theta_t - \alpha F(\theta_t)^{-1} \hat{g}_t.$$

对 MLP 精确构造和求逆完整 Fisher 矩阵代价很高，因此程序采用对角经验 Fisher 近似：

$$\hat{F}_t = \beta \hat{F}_{t-1} + (1 - \beta)(\hat{g}_t \odot \hat{g}_t),$$

$$\theta_{t+1} = \theta_t - \alpha \left(\text{diag}(\hat{F}_t) + \lambda_{\text{NG}} I \right)^{-1} \hat{g}_t.$$

其中 λ_{NG} 为阻尼项，用于避免 Fisher 对角元素过小导致步长过大。这种实现保留了自然梯度按参数敏感度自适应缩放梯度的核心思想，同时避免了完整 Fisher 矩阵的存储和求逆。

4 实验设置

两种优化器使用相同的数据划分、相同初始参数和相同 minibatch 顺序。主要参数如下：

项目	数值
训练集大小	4000
测试集大小	1000
隐层神经元	64
训练轮数	12
Batch size	128
SGD 学习率	0.25
NG 学习率	0.04
NG 阻尼	0.5
NG Fisher 衰减系数	0.9



图 1: 本次离线运行所用的 28×28 数字样例

图 1 展示了本次离线实验使用的数据样例。由于当前目录中没有标准 MNIST IDX 文件，程序自动生成了与 MNIST 输入格式一致的 28×28 灰度数字图像。每一列对应一个数字类别，图像中加入了随机平移、噪声和局部扰动，因此它不是完全规则的模板分类，但仍然比真实 MNIST 简单。这个图的作用是说明本次结果用于验证 SGD 与 NG 的训练流程，若换成真实 MNIST 文件，网络结构和优化器代码不需要改变。

5 运行结果对比

本次运行的最终结果如下：

优化器	最终训练准确率	最终测试准确率	最终测试损失	最佳测试准确率
SGD	1.0000	0.9980	0.0324	0.9980
NG	0.9985	0.9960	0.0805	0.9960

图 2 给出了测试集准确率随训练轮数变化的曲线。红色曲线为 SGD，蓝色曲线为 NG。可以看到 SGD 在前两轮上升更快，第 2 轮已经达到 0.9860，第 5 轮达到本次最高测试准确率 0.9980。NG 的前期增长更平滑，第 2 轮为 0.9230，第 10 轮达到 0.9960。这说明在本实验的小型网络和较规则数据上，普通 SGD 已经非常高效；对角 Fisher 近似的 NG 虽然也能稳定收敛，但因为阻尼项使更新更保守，达到高准确率所需轮数更多。




图 2: SGD 与 NG 的测试准确率曲线




图 3: SGD 混淆矩阵




图 4: NG 混淆矩阵

图 3 和图 4 为两种优化器在测试集上的混淆矩阵。矩阵的行表示真实类别，列表示预测类别；对角线越亮、非对角线数字越少，说明分类越准确。SGD 的 1000 个测试样本中只有 2 个错误：一个数字 6 被误分为 5，一个数字 9 被误分为 8。NG 的错误数为 4 个：一个 2 被误分为 3，两个 6 被误分为 5，一个 9 被误分为 8。两种方法的错误都集中在形状相近的类别上，例如 6 与 5 的上半部分结构相似，9 与 8 在加入噪声后也容易混淆。这与准确率曲线中的结论一致：两者最终都学到了有效分类边界，SGD 在本次设置下略好。

6 解释与讨论

从曲线可以看出，SGD 在该离线数字数据上收敛更快：第 2 轮测试准确率已经达到 0.9860，第 5 轮达到最佳准确率 0.9980。NG 的前期准确率略低，第 2 轮为 0.9230，但后续持续上升，第 10 轮达到 0.9960。最终两者的分类性能非常接近，SGD 在本次实验中略优。

这个结果有三点原因。第一，本次数据较规则，普通 SGD 已经可以用较大的学习率快速找到可分边界，因此自然梯度的几何预条件优势不明显。第二，程序使用的是对角 Fisher 近似，忽略了不同参数之间的相关性；它比完整自然梯度更省计算，但也削弱了方向修正能力。第三，NG 对阻尼项较敏感：阻尼过小会导致某些参数方向步长过大，阻尼过大又会退化为较保守的自适应梯度下降。

因此，本实验说明：在小型 MLP 和较简单的数字分类数据上，SGD 简洁、稳定、速度快；NG 的理论优势在于考虑模型分布的局部几何，但实际效果依赖 Fisher 近似质量和阻尼调参。若使用真实 MNIST、较深网络或更病态的参数尺度，完整 Fisher、K-FAC 或更高质量的自然梯度近似可能更能体现优势。

7 文件说明

- `mnist_sgd_ng.py`: 主程序，包含数据读取、MLP、SGD/NG 训练和结果输出；
- `requirements.txt`: 运行依赖；
- `results/results.csv`: 每轮训练与测试指标；
- `results/summary.json`: 最终对比摘要；
- `results/accuracy_curve.png`: 准确率曲线；
- `results/confusion_sgd.png` 与 `results/confusion_ng.png`: 混淆矩阵。